


Distributional Reinforcement Learning in Dopamine Neurons

Neuroscience Project, Fall 2025


汇报人：黄荣昊 崔泽宇 陈浩扬



Overview

- **Background**
- **Cat-Car Task Simulation**
- **Neural Evidence for Distributional Reward Prediction**
- **Decoding and Model Comparison**
- **Conclusion**
- **References**

Pavlov's Experiment



Pavlov and His Dog

一百多年前，巴甫洛夫做了一个实验：
他给狗听一个蜂鸣声，然后过一会儿给它食物。几轮训练之后，狗一听到蜂鸣就开始流口水——尽管食物还没来。

——狗学会了预测奖励！



Dopamine and Reward Prediction

- 多巴胺神经元 \approx 奖励预测误差信号；
- 这与人工智能中的「时序差分学习 (TD learning)」高度一致：
 - “预测误差” 用来更新模型，让它学得越来越准；
- 那么核心问题来了：
 \rightarrow **多巴胺神经元只编码平均奖励，还是完整的奖励分布？**

Classical TD

我们通过“当前的预测值”和“实际的回报”之间的差值 (prediction error) , 来更新模型。

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

这个 δ 是预测误差 (prediction error) , 用来调整我们对当前状态的价值判断。

但是仅仅估计期望值够吗?



Distributional TD

$$V^{(i)}(s_t) \leftarrow V^{(i)}(s_t) + \begin{cases} \alpha_+^{(i)} \cdot \delta^{(i)} & \text{if } \delta^{(i)} > 0 \\ \alpha_-^{(i)} \cdot \delta^{(i)} & \text{if } \delta^{(i)} < 0 \end{cases}$$

我们可以把这些不同的单元理解为“大脑中对未来持不同态度的神经元”

- 这种机制构建了一个异质性的价值表示系统
- 在神经实验中也观察到类似现象：不同DA神经元对应不同反应模式（乐观、中性、悲观）



为了比较经典TD和分布式TD模型的差异，
我们设计了一个具有“**猫猫 vs 汽车**”风格的图像分类任务，
来模拟奖励结构的不确定性和变化。



Experiment Setup

- **Car** : 代表稳定的奖励来源，始终给予 **+1** 分。
- **Cat** : 代表具有不确定性的刺激，前期有 **50%** 概率得到 **+5** 分，
50% 概率得到 **-3** 分，虽然平均也是 +1 分，但波动很大。

之后，我们在任务第2阶段引入突变：
——猫图像不再是波动奖励，而是 **100%** 给予 **+5** 分。


-
- **Classical TD**: 输出一个标量，学习平均值。
 - **Distributional TD** : 输出多个值，代表奖励的不同分位点。

Result

- **Task 1** 学习阶段: 两个模型都迅速收敛
- **Task 2** 迁移阶段: 红线(分布式)迅速下降,
绿线(经典)缓慢下降



- 经典 TD 模型需要慢慢重新学习新的平均值;
- 分布式 TD 模型因为之前已经“知道”+5 分存在,
只需微调概率权重即可完成迁移, 表现出显著更快的适应速度。



-> 分布式模型更擅长应对环境的不确定性和动态变化。

Neural Evidence for Distributional Reward Prediction

多巴胺 (DA) 神经元是否在编码 “奖励分布” , 而不只是平均值?

我们提出的分布式 TD (Distributional TD) 首先是一个假设模型。


- 下一步关键是验证：它是否更贴近真实的生物神经系统？
 - 为此我们分析小鼠 DA 神经元在两类任务中的放电数据，寻找“编码奖励分布”的证据。
-
- 实验1：变量奖励体积任务 → 反转点 (Reversal Point)
 - 实验2：变量奖励概率任务 → 乐观/悲观分化 (t 统计量双峰)



Experiment 1

任务示意

- 提示音 (cue) → 等待 (delay) → 获得液体奖励
- 奖励体积从 5 个不同大小中随机抽取
- 数据中记录了 40 个 DA 神经元的反应




图：左：经典 TD 单元

中：分布式 TD 单元

右：真实 DA 神经元

**DA 神经元的反转点几乎覆盖整个奖励区间
——有人偏“乐观”，有人偏“悲观”，有人居中。**



Experiment 2

任务示意

- cue 表示奖励概率: 10% / 50% / 90%
- 我们重点观察 50% cue (最模糊、最能区分模型)
- 如果只编码均值: 神经元对 50% cue 应该趋同
- 如果编码分布: 可能出现乐观/悲观两类偏向

预测对比

- 经典 TD 预测: 50% cue 反应应围绕 “平均预测”，差异小
- 分布式 TD 预测: 50% cue 下会分裂为偏向高概率/低概率的不同单元




图: 左: 真实DA响应

中: 真实GAB响应

右: 模拟的分布式TD分布

真实 DA 数据的 t 统计量呈 “双峰/两团”

Comparison Conclusion


生物证据支持“分布式奖励编码”：

对比维度	经典 TD	分布式 TD	真实 DA 神经元
编码内容	主要是均值	多通道表示分布 (不同位置/分位点)	反应多样、方向各异
神经元多样性	低	高	高
实验1：体积反转点	倾向集中	覆盖整个区间	覆盖整个区间
实验2：50% cue	单峰/趋同	乐观-悲观分化	乐观-悲观分化 (双峰)

- 结论：DA 神经元群体更像“分布式预测单元集合”，而不是“同一个均值预测器的复制品”。

因此，两项任务共同指向：DA神经元群体存在稳定的多样性，符合一种‘分布式编码奖励分布’的机制。

这为Distributional TD 式单元提供了生物学层面的支持证据。



Decoding & Model Comparison

本部分的核心目标，是通过计算建模来论证：

分布式强化学习模型比传统TD模型能更好地解释多巴胺神经元的编码机制

为实现这一目标，我们尝试构建了一种解码分析工具。

分布式TD vs 经典TD




Reward Decoding

| 模型是否只是拟合数据？我们还能做得更进一步：

我们尝试使用解码分析 (decoding analysis) 从神经元群体活动中反向还原奖励分布，进一步测试 Distributional TD 的生物合理性。

- Decoding函数
- 真实神经元数据
- 人工制造奖励



Decoding Function

解码 (Decoding) 的意义:

如果我们能从一个神经元群体的活动中，反向推断出它们所编码的完整奖励分布，就能为分布式假说提供有力证据。

挑战

在分布式假说当中，神经元并非“客观”的传感器，它们有自己的“偏好”或不对称性 (Asymmetry)。



Decoding Function

我们假设每个神经元编码的是奖励分布的一个**期望分位数 (Expectile)**，由其不对称性参数 τ 决定。解码器通过最小化一个特定的损失函数来寻找最佳的奖励分布。

期望分位数回归损失函数：

$$\mathcal{L}_\tau(y, \hat{y}) = |\tau - I(y < \hat{y})| \cdot (y - \hat{y})^2$$

y 是真实的奖励值， \hat{y} 是神经元的预测。

$(y - \hat{y})^2$ 是标准的预测误差。

τ 是神经元的乐观悲观程度 (0到1之间，0.5代表中立)。

$|\tau - I(y < \hat{y})|$ 是**不对称惩罚项**。它使得当预测偏高或偏低时，受到的“惩罚”是不同的，这正是这个公式的关键。

Decoding Function

run_expectile_decoding:

- 接收一群神经元的“读数” (reversal_points) 和它们的“个性” (τ)。
- 内部定义了 expectile_loss_fn 来计算当前预测的“离谱指数”。
- 通过 scipy.optimize.minimize 算法，不断调整一个猜测的奖励分布，直到找到那个能让“离谱指数”最小化的最佳分布。

```
for _ in range(max_epochs):
    samples = np.random.uniform(minv, maxv, size=(max_samples, N))
    fvalues = np.array([expectile_loss_fn(points, tau, x0) for x0 in samples])
    x0 = np.sort(samples[fvalues.argmin()])
    result = scipy.optimize.minimize(
        lambda x: expectile_loss_fn(points, tau, x),
        method=method,
        bounds=[(minv, maxv)] * len(x0),
        x0=x0
    )
```


Classical VS Distributional

假设每个 DA 神经元代表一个特定 expectile，我们利用这些神经元对奖励的响应，用回归方式尝试重建整个奖励分布。

我们对比了三种来源的奖励分布：

- 经典 TD 模型模拟数据
- 分布式 TD 模型模拟数据
- 真实奖励分布

得到的分布图像如下：



经典TD下模拟的分布只还原出单一平均值分布，丢失结构。
分布式TD模拟的分布结构高度吻合 ground truth。



只有 Distributional TD 架构能极大程度上还原出奖励信号的真实分布

Conclusion

我们通过一个完整链条的分析：



发现：

- 多巴胺神经元不只是编码平均值，它们可能携带**整个奖励分布的编码信息**；
- Distributional TD 在生物解释力、学习效率、解码能力上**均优于经典 TD**；
- 这为理解 DA 系统的灵活性与不确定性下的学习策略提供了新视角。

References

- [1] Margarida Sousa, Paweł Bujalski, Bruno F. Cruz, Kenway Louie, Daniel C. McNamee, and Joseph J. Paton. A multidimensional distributional map of future reward in dopamine neurons. *Nature*, 642:691–699, 2025.
- [2] Will Dabney, Zeb Kurth-Nelson, Naoshige Uchida, Christopher K Starkweather, Demis Hassabis, Remi Munos, and Matthew Botvinick. A distributional code for value in dopamine-based reinforcement learning. *Nature*, 577(7792):671–675, 2020.
- [3] Mark Rowland, Marc G Bellemare, Will Dabney, Remi Munos, and Yee Whye Teh. Statistics and samples in distributional reinforcement learning. In *International Conference on Machine Learning*, pages 5528–5536. PMLR, 2019.

THANK YOU

For your attention

